Tableau de veille

Axes d'amélioration :

Réaliser un audit du notebook afin de voir les problèmes et ses conséquences métier.

Problème	Conséquences
Jointures entre ERP, Web et liaison insuffisamment contrôlées	Ventes perdues, dupliquées ou mal associées aux produits
Références produits à corriger	Chiffres d'affaires ou stocks potentiellement erronés
Calcul du Pareto 80/20 à fiabiliser	Mauvaise identification des produits qui contribuent le plus au CA
Analyse des marges ou des stocks insuffisamment validée	Recommandations commerciales fragiles
Notebook long et difficile à réexécuter	Temps perdu et résultats difficiles à reproduire

Solutions comparées :

Comparaison de deux solutions : une alliant Pandas avec des tests générés par IA, et une solution utilisant la librairie Great Expectations afin de réaliser des tests sur le DataFrame final.

Critère	Pandas + tests IA	Great Expectations
Qualité des contrôles	Dépend des tests écrits	Règles de validation structurées
Robustesse	Bonne si les tests sont complets	Bonne si les règles sont bien définies
Temps de mise en place	Faible à modéré	Potentiellement plus élevé
Reproductibilité	Bonne dans un notebook versionné	Bonne avec une configuration versionnée
Maintenance	Code à maintenir soi-même	Configuration et dépendances à maintenir
Sécurité	Traitement local possible	Traitement local possible selon l'installation

Sources :

Solution	Source à consulter
Pandas	https://pandas.pydata.org/docs
Great Expectations	https://docs.greatexpectations.io/docs/home
ChatGPT	https://help.openai.com/
Gemini	https://support.google.com/gemini/#topic=15280100

Cahier des charges

Amélioration du projet de vente de vins

1. Contexte

L'entreprise Bottleneck commercialise des vins et divers alcools via plusieurs sources de données, notamment un système ERP et une plateforme Web. Les données doivent être regroupées et analysées afin de fournir une vision cohérente des ventes et des produits.

2. Parties prenantes

- Direction : piloter le chiffre d'affaires et identifier les priorités commerciales.
- Responsable commercial : repérer les produits les plus performants.
- Responsable des stocks : détecter les incohérences et mieux comprendre les stocks disponibles.
- Data Analyst : préparer, contrôler et analyser les données.

3. Problématique métier

Comment fiabiliser les données issues des différentes sources et produire des indicateurs fiables permettant à la direction de mieux comprendre les ventes, les marges et les stocks de vins et autres alcools ?

4. Périmètre

- Inclus : fichiers ERP, Web et liaison ; rapprochement des produits ; qualité des données ; chiffre d'affaires ; quantités ; Pareto ; stocks et marges si les données permettent de les calculer.

5. Contraintes

- Fichiers de formats et de structures différents.
- Références produits potentiellement manquantes ou mal associées.
- Définition des indicateurs dépendante des colonnes réellement disponibles.
- Analyse reproductible dans un environnement Python documenté.
- Pas de modification des fichiers sources originaux.

6. Livrables

Un notebook explicatif, un tableau de veille, un cahier des charges avec critères d'acceptation, un Kanban des tâches à effectuer, des contrôles de qualité automatisés, un export des résultats, une synthèse métier présentant les constats, les limites et les recommandations, et une documentation des étapes effectuées avec l'IA.

Liste de critères d'acceptation

Domaine	Critère proposé
Qualité	Contrôle des jointures : nombre de lignes, correspondances, doublons
Intégrité	Aucune duplication inexpliquée de ventes après rapprochement
Fiabilité	Les totaux de CA sont rapprochés des données sources selon une règle documentée
Pareto	Produits triés par CA décroissant, cumul calculé et seuil de 80% identifié correctement
Reproductibilité	Le notebook s'exécute de bout en bout depuis les fichiers sources
Lisibilité	Chaque indicateur est défini et accompagné d'une interprétation métier, chaque étape est correctement notée
Documentation	Les hypothèses, anomalies, corrections et limites sont consignées

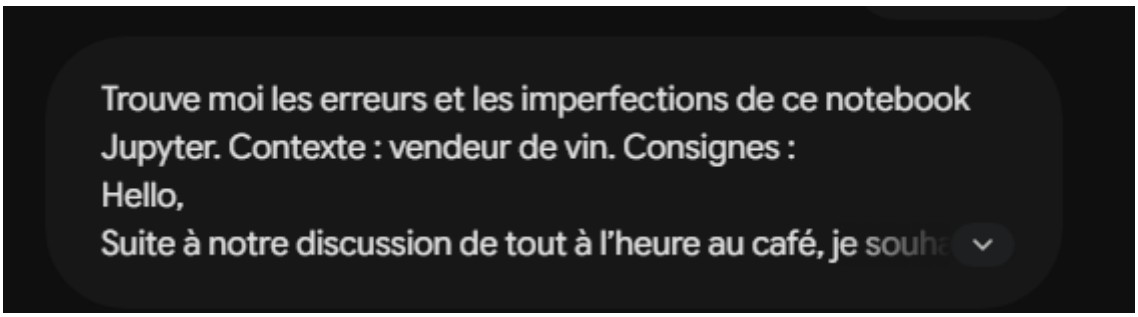
Plan de formation

Séquence	Contenu	Public	Objectif
Présentation des indicateurs	Définition du chiffre d'affaires, des marges et des indicateurs de stock	Direction et responsables métier	Comprendre les indicateurs
Lecture des résultats	Interprétation des graphiques, du Pareto et des corrélations	Direction et responsable commercial	Identifier les tendances
Compréhension des limites	Données manquantes, références non rapprochées et limites des calculs	Responsables métier	Comprendre les réserves associées aux résultats
Utilisation des livrables	Lecture du rapport, consultation des exports et remontée des anomalies	Utilisateurs du projet	Exploiter les résultats et signaler les problèmes

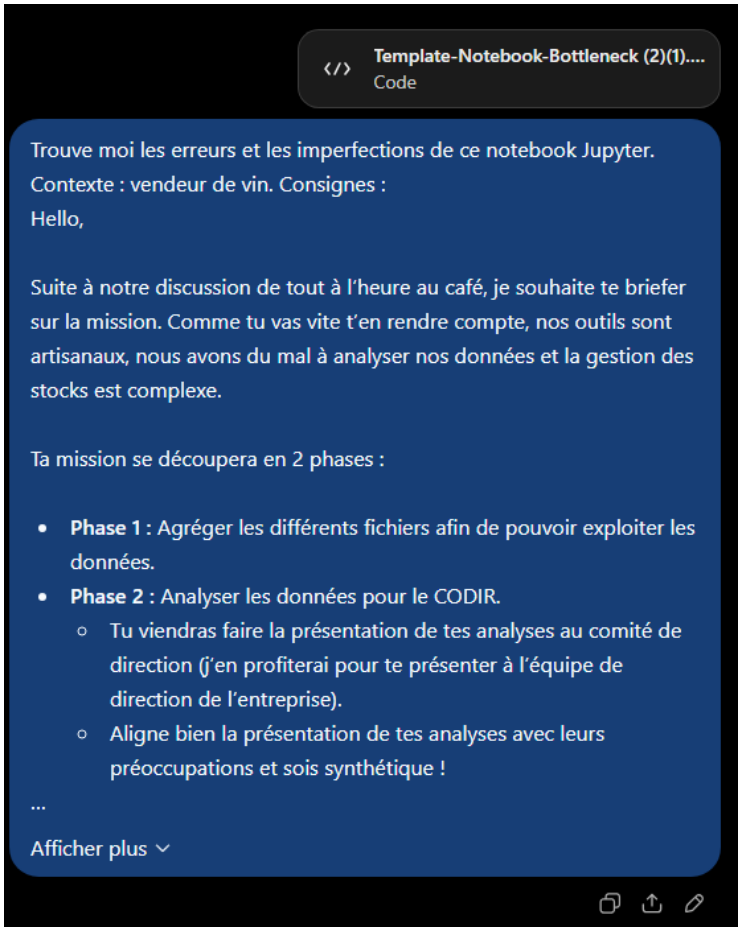
Documentation du projet 6 assisté par l'IA

Deux méthodes de LLM vont être utilisées et comparées : **ChatGPT** et **Gemini**. En premier lieu, je leur fournis mon notebook Jupyter et leur demande de trouver les erreurs et imperfections présentes dans le notebook. Voici les prompts écrits avec en prime les consignes du projet 6.

Gemini :



ChatGPT :



ChatGPT me trouve plusieurs erreurs critiques :

1. Les erreurs les plus importantes à corriger

Critique **1. Le calcul du taux de marge est incorrectement nommé**

Dans la cellule 84, tu calcules :

$$\frac{\text{Prix HT} - \text{Prix d'achat}}{\text{Prix HT}}$$

Cette formule correspond au **taux de marque**, et non au taux de marge. Le taux de marge se calcule en divisant la marge commerciale par le prix d'achat HT.

Conséquence : les résultats peuvent être numériquement cohérents avec la formule choisie, mais leur interprétation économique est fausse.

Critique **2. Le calcul du chiffre d'affaires suppose que `price` est le bon prix de vente**

Dans la cellule 73, tu fais `price * total_sales`. Le calcul est correct si `price` correspond au prix de vente effectivement facturé et si `total_sales` correspond au nombre d'unités vendues sur la même période.

Mais il faut vérifier si `price` est TTC ou HT, si les ventes sont cumulées ou limitées à une période, et si les remises ou remboursements doivent être pris en compte. Le notebook ne démontre pas ces points.

Critique **3. Les produits sans correspondance risquent d'être mal traités**

Les cellules 51 à 57 effectuent les jointures. La première utilise `how='outer'`, ce qui est utile pour repérer les références sans correspondance. La seconde utilise `how='left'`, ce qui conserve le catalogue issu de l'ERP et de la table de liaison, mais exclut les produits présents uniquement sur le site Web.

Il faut distinguer les produits sans identifiant Web, les références ERP sans liaison et les références Web sans produit ERP. Ces situations ne sont pas équivalentes.

Critique **4. La rotation des stocks traite mal les produits qui ne se vendent pas**

Dans la cellule 80, tu calcules le nombre de mois de stock, puis tu remplaces les valeurs infinies par zéro.

Or, un produit ayant du stock mais aucune vente ne possède pas zéro mois de stock : il n'a aucune rotation observée sur la période et peut représenter un stock dormant. Le remplacer par zéro inverse le sens de l'indicateur.

Critique **5. Le test de cohérence du statut de stock est mal conçu**

Dans la cellule 18, tu compares la somme de deux colonnes textuelles :

```
df_erp["stock_status"].sum() == df_erp["stock_status_2"].sum()
```

Ce n'est pas une façon fiable de vérifier que deux colonnes sont identiques. La comparaison doit être faite ligne par ligne, en comptant les désaccords.

Critique **6. Le calcul du 20/80 ne compte pas correctement le produit qui franchit le seuil**

Dans les cellules 75 et 78, tu comptes les références dont le chiffre d'affaires ou les ventes cumulés restent inférieurs ou égaux à 80 %.

Le produit qui fait passer le cumul de 79 % à 83 %, par exemple, est exclu du décompte. Le nombre de références obtenu sous-estime donc généralement le nombre nécessaire pour atteindre au moins 80 %.

ChatGPT me trouve plusieurs erreurs critiques :

- Calcul du taux de marge erroné,
- Vérifier si le prix est HT ou TTC et d'autres problèmes non présents dans le brief,
- Des problèmes dans les jointures,
- Des problèmes dans la solution initiale trouvée concernant la rotation des stocks,
- Test de cohérence du statut du stock mal conçu,
- Le calcul du 20/80 est également mal conçu.

ChatGPT me propose enfin une correction des cellules male conçues avec un affichage de l'erreur, puis une correction. Exemple dès le chargement du fichier :



Ensuite, ChatGPT me trouve des imperfections et me demande de les corriger :

3. Les imperfections transversales du notebook

Au-delà des cellules individuelles, voici les problèmes qui nuisent à la fiabilité et à la lisibilité de l'ensemble.

Problème	Conséquence	Amélioration
Corrections manuelles de valeurs	Modifications difficiles à justifier ou reproduire	Documenter chaque anomalie et sa correction
Jointures sans validation systématique	Doublons ou pertes de produits possibles	Contrôler les clés, les cardinalités et les indicateurs de jointure
Absence de synthèse des anomalies	Difficile de démontrer les huit erreurs demandées	Créer un tableau de suivi des anomalies
Seuils statistiques figés	Résultats obsolètes si les données changent	Calculer les seuils à partir des données
Exclusions non documentées	Risque de biais dans les analyses	Conserver le nombre de lignes avant/après chaque filtre
Variables non agrégées par référence	Risque de compter plusieurs fois un produit	Construire une table de référence unique pour les analyses commerciales
Conclusions peu détaillées	Le CODIR ne sait pas quelle décision prendre	Associer chaque résultat à une recommandation opérationnelle
Pas de contrôle de reproductibilité	Les résultats peuvent dépendre de l'ordre d'exécution	Redémarrer le noyau et exécuter toutes les cellules dans l'ordre

Enfin, ChatGPT me résume le travail à effectuer sous forme de tableau :

5. Ce que je prioriserais avant la présentation au CODIR

Priorité 1 — Fiabiliser le référentiel produit

Résoudre les problèmes de clés et de jointures, identifier les références sans correspondance et vérifier les doublons. C'est la base de toutes les analyses suivantes.

Priorité 2 — Corriger les indicateurs financiers

Vérifier la définition du CA, distinguer taux de marge et taux de marque, et calculer la valorisation des stocks sur des données fiables.

Priorité 3 — Refaire les analyses commerciales

Recalculer les tops produits, les analyses 20/80, les prix atypiques et les mois de stock. Vérifier que les ventes et les stocks couvrent des périodes cohérentes.

Priorité 4 — Transformer les résultats en décisions

Présenter quelques indicateurs fiables, les anomalies principales, les produits à surveiller et des recommandations sur les approvisionnements, les stocks dormants et la qualité des données.

Gemini me trouve également des erreurs, mais qui sont déjà corrigées dans le notebook, ce qui me semble être un premier écueil quant à sa fiabilité :

- **Doublons et données parasites dans le fichier Web :**
  - Le fichier `web.xlsx` contient des lignes de type `attachment` (pièces jointes/images WordPress) qu'il faut filtrer et supprimer pour ne garder que les produits réels (`product`). IPYNB
  - La présence de codes articles (`sku`) absents ou mal formatés (ex. des suffixes `-1` ou des chaînes textuelles comme `bon-cadeau-25-euros`) nécessite un nettoyage rigoureux avant la jointure. IPYNB

En effet, les lignes attachment ont été supprimées lors du merging :

Etape 3.2 - Jonction du fichier df_merge et df_web

```
#Fusionner les datasets df_merge et df_web
df_web = df_web.rename(columns={'sku': 'id_web'})
df_web = df_web[df_web['post_type'] != 'attachment']
```

Toutefois, Gemini me propose plusieurs axes d'améliorations :

3. Propositions de solutions et recommandations pour le système

1. **Amélioration de la saisie dans l'ERP et WordPress :**
   - Mettre en place des contraintes de validation (validation *front-end* et *back-end*) pour empêcher la saisie de prix ou de stocks négatifs.
   - Synchroniser automatiquement les états de stock (`instock` / `outofstock`) avec la quantité réelle en stock pour éviter les incohérences e-commerce.
2. **Nettoyage des données :**
   - Traiter les valeurs aberrantes en distinguant les erreurs de saisie (à corriger ou exclure) des véritables produits de luxe haut de gamme (à conserver).
3. **Compléments indispensables à rajouter dans le Notebook :**
   - Calculer explicitement le **taux de marge** (`(Prix de vente - Prix d'achat) / Prix de vente`) pour chaque produit.
   - Calculer la **rotation des stocks** et le **nombre de mois de stock**.
   - Ajouter une matrice de corrélation (avec `seaborn.heatmap`) pour répondre à la demande du CODIR concernant les liens entre prix, stock, ventes et marges.
   - Préparer des graphiques synthétiques et épurés, adaptés à une présentation exécutive pour le comité de direction.

Le travail préliminaire déterminé est donc de :

- Nettoyage des données à refaire,
- Le calcul du taux de marge doit être corrigé, tout comme le calcul de rotation des stocks et du nombre de mois de stock,
- Une matrice de corrélation doit être faite,
- Des graphiques explicatifs et compréhensifs doivent être ajoutés.

ChatGPT	Gemini
Calcul du taux de marge erroné, Vérifier si le prix est HT ou TTC et d'autres problèmes non présents dans le brief, Des problèmes dans les jointures, Des problèmes dans la solution initiale trouvée concernant la rotation des stocks, Test de cohérence du statut du stock mal conçu, Le calcul du 20/80 est également mal conçu.	Nettoyage des données à refaire, Le calcul du taux de marge doit être corrigé, tout comme le calcul de rotation des stocks et du nombre de mois de stock, Une matrice de corrélation doit être faite, Des graphiques explicatifs et compréhensifs doivent être ajoutés.

On retrouve donc certains des mêmes problèmes dans les deux options de LLM, notamment le taux de marge et la rotation des stocks. La présence d'une matrice de corrélation doit également être une priorité car elle était demandée spécifiquement dans le brief.

Premières impressions :

Pour le même prompt, ChatGPT semble être davantage exhaustif et propose des corrections des cellules problématiques avec des solutions pragmatiques, alors que Gemini propose une vision différente, en pointant les erreurs commises mais en ne mâchant pas automatiquement le travail de l'utilisateur.

Corrections effectuées

1. Chargement des fichiers

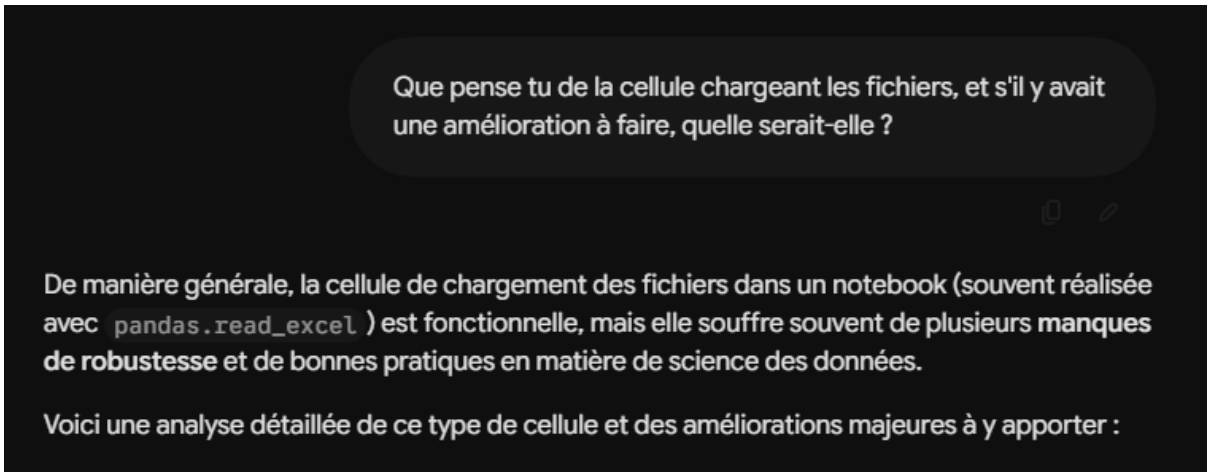
Problème : le chemin était celui de mon ordinateur. Je l'ai modifié afin qu'il puisse être lu par n'importe quelle machine (à partir de ChatGPT).

1.2 - Chargements des fichiers ¶

```
from pathlib import Path

data_dir = Path("Dataframes")
#Importation du fichier web.xlsx
df_web = pd.read_excel(data_dir / "web.xlsx")
#Importation du fichier erp.xlsx
df_erp = pd.read_excel(data_dir / "erp.xlsx")
#Importation du fichier liaison.xlsx
df_liaison = pd.read_excel(data_dir / "liaison.xlsx")
```

ChatGPT m'ayant proposé sa solution de lui-même, je vais demander une correction spécifique à ce problème à Gemini.



Gemini va plus loin en proposant une gestion et un affichage des erreurs.

3. Exemple de code optimisé

Voici à quoi pourrait ressembler une cellule de chargement professionnelle :

Python

```python
import pandas as pd
from pathlib import Path

# Définition du dossier contenant les données (par exemple un sous-dossier 'data' ou
data_path = Path('.')

try:
    # Chargement des fichiers avec pathlib
    df_erp = pd.read_excel(data_path / 'erp.xlsx')
    df_web = pd.read_excel(data_path / 'web.xlsx')
    df_liaison = pd.read_excel(data_path / 'liaison.xlsx')

    print("Fichiers chargés avec succès !\n")

    # Affichage rapide des dimensions pour contrôle qualité immédiat
    print(f"Dimensions - ERP : {df_erp.shape}")
    print(f"Dimensions - Web : {df_web.shape}")
    print(f"Dimensions - Liaison : {df_liaison.shape}")

except FileNotFoundError as e:
    print(f"Erreur critique : Impossible de trouver l'un des fichiers de données. Dé
except Exception as e:
    print(f"Une erreur inattendue est survenue lors du chargement : {e}")
```

Ce que cela vous apporte :

En structurant votre chargement ainsi, vous évitez les blocages inopinés lors de l'exécution du notebook et vous obtenez un retour visuel immédiat sur la structure de vos données sources (lignes et colonnes).

1.2 - Chargements des fichiers

```python
data_path = Path('Dataframes')

try:
    # Chargement des fichiers avec pathlib
    df_erp = pd.read_excel(data_path / 'erp.xlsx')
    df_web = pd.read_excel(data_path / 'web.xlsx')
    df_liaison = pd.read_excel(data_path / 'liaison.xlsx')

    print("Fichiers chargés avec succès !\n")

    # Affichage rapide des dimensions pour contrôle qualité immédiat
    print(f"Dimensions - ERP : {df_erp.shape}")
    print(f"Dimensions - Web : {df_web.shape}")
    print(f"Dimensions - Liaison : {df_liaison.shape}")

except FileNotFoundError as e:
    print(f"Erreur critique : Impossible de trouver l'un des fichiers de données. Détails : {e}")
except Exception as e:
    print(f"Une erreur inattendue est survenue lors du chargement : {e}")
```

```
C:\Users\capel\anaconda3\Lib\site-packages\openpyxl\worksheet\_read_only.py:85: UserWarning: Unknown extension is not supported and will be removed
  for idx, row in parser.parse():
Fichiers chargés avec succès !

Dimensions - ERP : (825, 6)
Dimensions - Web : (1513, 29)
Dimensions - Liaison : (825, 2)
C:\Users\capel\anaconda3\Lib\site-packages\openpyxl\worksheet\_read_only.py:85: UserWarning: Unknown extension is not supported and will be removed
  for idx, row in parser.parse():
C:\Users\capel\anaconda3\Lib\site-packages\openpyxl\worksheet\_read_only.py:85: UserWarning: Unknown extension is not supported and will be removed
  for idx, row in parser.parse():
```

Je choisis cette méthode pour sa gestion des erreurs.

2. Calcul du taux de marge

Dans mon notebook, le calcul du taux de marge était le suivant :

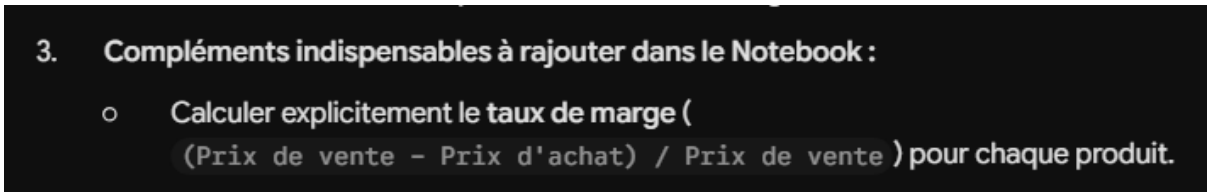
```
##########################
# Analyse du taux de marge #
##########################

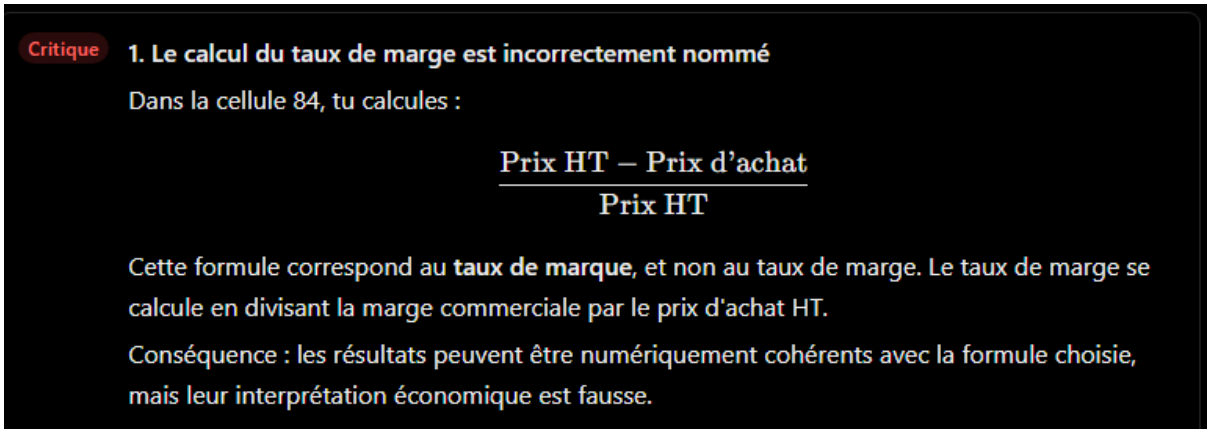
#Création de la colonne Prix HT
df_merge['prix_ht'] = df_merge['price'] / 1.2
#Création de la colonne Taux de marge
df_merge['taux_marge'] = (df_merge['prix_ht'] - df_merge['purchase_price']) / df_merge['prix_ht']
#Afficher le prix minimum de la colonne "taux_marge"
taux_min = df_merge['taux_marge'].min()
print('Taux minimum :', taux_min)
#Afficher le prix maximum de la colonne "taux_marge"
taux_max = df_merge['taux_marge'].max()
print("Taux maximum :", taux_max)

print(df_merge['taux_marge'])
```

```
Taux minimum : -6.3498814229249
Taux maximum : 1.651
0      0.410909
1      0.392727
2      0.373423
3      0.355591
4      0.404632
         ...
820    0.398452
821    0.379871
822    0.373867
823    0.355200
824    0.392302
Name: taux_marge, Length: 825, dtype: float64
```

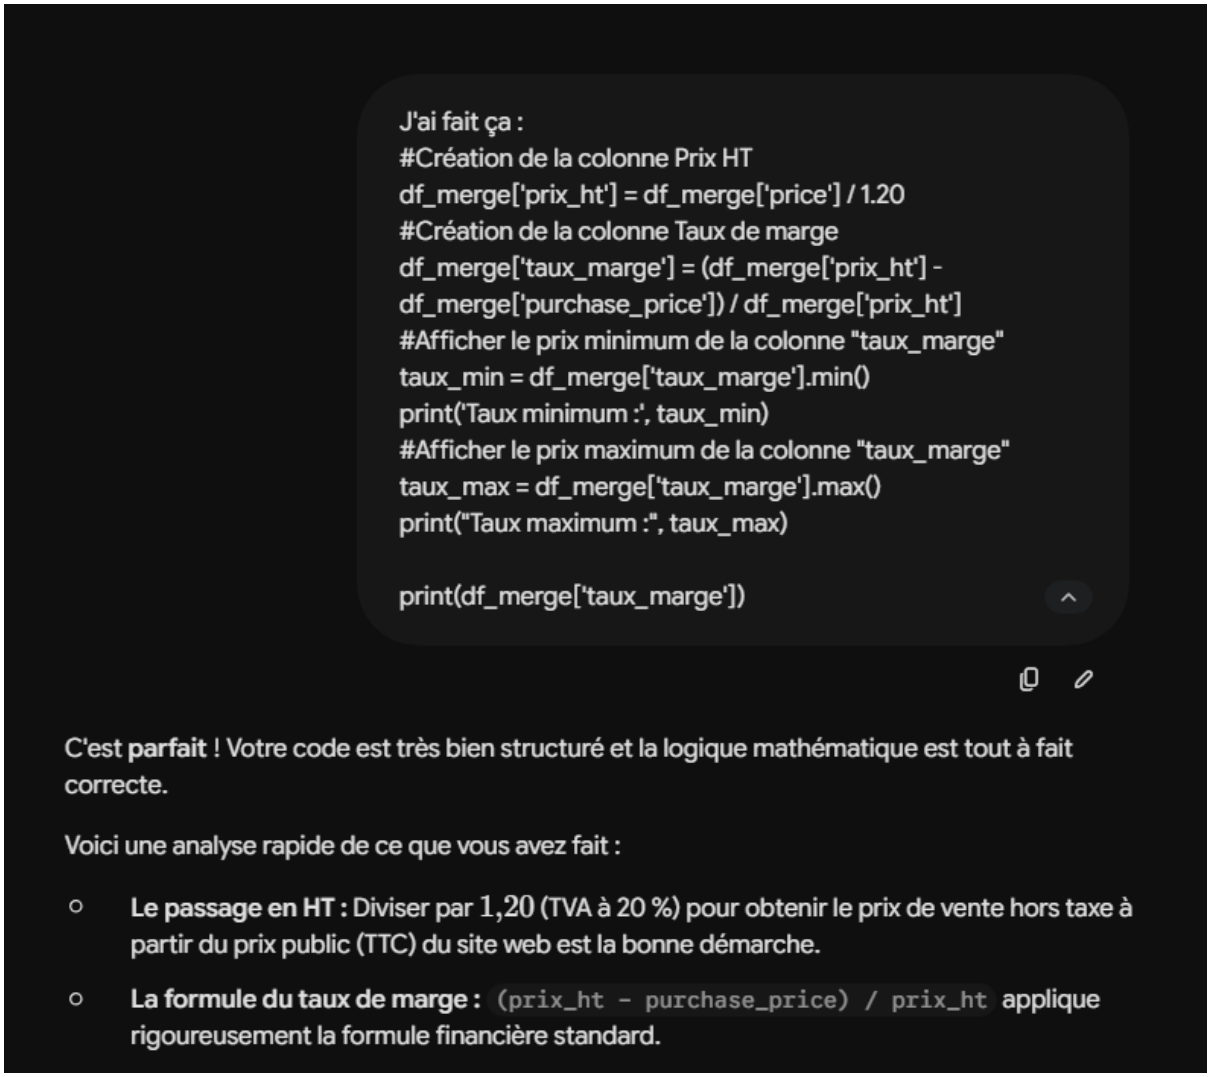
Gemini et ChatGPT m'ont tous deux fait part d'une erreur dans le calcul.





L'approche effectuée était bien Prix de vente HT – Prix d'achat / Prix de vente HT.
Comme les deux LLM me disent qu'il y a une erreur, je vérifie à nouveau…

Sur Gemini :



ChatGPT m’en dit plus sur les problèmes qu’il a détecté.

F. Marge commerciale

Cellules 84 à 88 — formule, nettoyage et agrégation

Le principal problème est la confusion entre taux de marge et taux de marque. Si tu veux présenter les deux indicateurs au CODIR, calcule-les séparément :

Python — Exécuter

```python
df_merge["prix_ht"] = df_merge["price"] / 1.20

df_merge["marge_unitaire"] = (
    df_merge["prix_ht"] - df_merge["purchase_price"]
)

# Taux de marque : marge / prix de vente HT
df_merge["taux_marque"] = (
    df_merge["marge_unitaire"] / df_merge["prix_ht"]
)

# Taux de marge : marge / prix d'achat
df_merge["taux_marge"] = (
    df_merge["marge_unitaire"] / df_merge["purchase_price"]
)
```

Ce code suppose une TVA de 20 % et des prix exprimés dans la même devise. Il faut vérifier ces hypothèses et traiter les prix de vente ou d'achat nuls avant de diviser.

La cellule 85 supprime les produits dont le prix est négatif après que le taux de marge a été calculé. Il serait préférable de créer d'abord un tableau de contrôle des anomalies, puis de calculer les indicateurs sur un périmètre clairement défini. Il ne faut pas supprimer les données sans conserver la trace des exclusions.

Enfin, la cellule 88 calcule une moyenne simple des taux de marge par type de produit. Cela donne le taux moyen par référence, mais pas nécessairement la rentabilité économique du type de produit. Pour le CODIR, il est intéressant de compléter cette moyenne par la marge totale et le taux de marge agrégé, calculés sur des données fiables.

Et en demandant plus d'explications :

A partir du notebook que je t'ai donné, tu m'as dit que le taux de marge était mal calculé.

Réfléchi pendant 16s

Oui. En reprenant précisément la cellule 84 de ton notebook, je confirme que **la formule utilisée calcule le taux de marque et non le taux de marge.**

1. La formule actuelle dans ton notebook

Dans ta cellule 84, tu as :

Python — Exécuter

```python
# Création de la colonne Prix HT
df_merge['prix_ht'] = df_merge['price'] / 1.2

# Création de la colonne Taux de marge
df_merge['taux_marge'] = (
    (df_merge['prix_ht'] - df_merge['purchase_price'])
    / df_merge['prix_ht']
)
```

Le problème se trouve dans le dénominateur : tu divises par le prix de vente HT, alors que le taux de marge se calcule en divisant par le prix d'achat HT.

ChatGPT me dit que le taux de marge se calcule en divisant par le prix d'achat HT.

Gemini me dit par contre que le taux de marge se calcule en divisant par le prix de vente HT.

Sur Wikipedia, la formule correcte m'est donnée :

Gestion [modifier | modifier le code]

En finance d'entreprise, le taux de marge se calcule en divisant la marge commerciale par le coût d'achat hors taxes :

$$\text{Taux-de-marge} = \frac{\text{Prix de vente HT} - \text{Cout d'achat HT}}{\text{Cout d'achat HT}} = \frac{\text{Marge commerciale}}{\text{Cout d'achat HT}}$$

Source : https://fr.wikipedia.org/wiki/Taux_de_marge

ChatGPT est donc plus fiable que Gemini sur ce sujet. Je corrige donc ma cellule.

Etape 5.4 - Analyse du taux de marge

```
############################
# Analyse du taux de marge #
############################

#Création de la colonne Prix HT
df_merge['prix_ht'] = df_merge['price'] / 1.20
#Création de la colonne Taux de marge
df_merge['taux_marge'] = (df_merge['prix_ht'] - df_merge['purchase_price']) / df_merge['purchase_price']
#Afficher le prix minimum de la colonne "taux_marge"
taux_min = df_merge['taux_marge'].min()
print('Taux minimum :', taux_min)
#Afficher le prix maximum de la colonne "taux_marge"
taux_max = df_merge['taux_marge'].max()
print("Taux maximum :", taux_max)

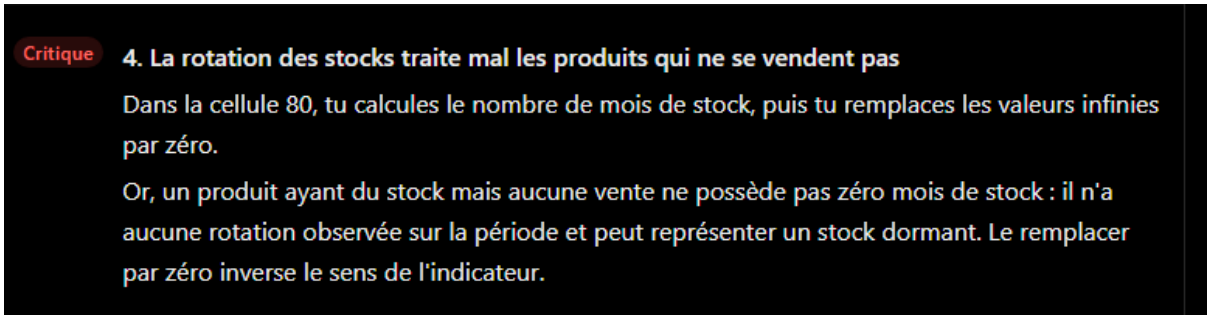
print(df_merge['taux_marge'])
```

```
Taux minimum : -0.8639433832386852
Taux maximum : 0.9141247090530442
0      0.697531
1      0.646707
2      0.595973
3      0.551808
4      0.679632
         ...
820    0.662377
821    0.612568
822    0.597104
823    0.550868
824    0.645554
Name: taux_marge, Length: 822, dtype: float64
```

Cela corrige les différentes cellules traitant du taux de marge dans le notebook.

3. Calcul de rotation des stocks

Un autre problème relevé par l'IA était la gestion de la rotation des stocks. Rappel pour ChatGPT :



Critique

4. La rotation des stocks traite mal les produits qui ne se vendent pas

Dans la cellule 80, tu calcules le nombre de mois de stock, puis tu remplaces les valeurs infinies par zéro.

Or, un produit ayant du stock mais aucune vente ne possède pas zéro mois de stock : il n'a aucune rotation observée sur la période et peut représenter un stock dormant. Le remplacer par zéro inverse le sens de l'indicateur.

E. Rotation et valorisation des stocks

Cellule 80 — nombre de mois de stock

La formule actuelle est :

Python Exécuter

```python
df_merge["rotation_stock"] = (
    df_merge["stock_quantity"] / (df_merge["total_sales"] / 12)
)
```

Elle suppose que les ventes couvrent douze mois. Si `total_sales` correspond aux ventes depuis la création du site ou sur une autre période, le résultat n'est pas un nombre de mois de stock fiable.

Si les ventes couvrent bien les douze derniers mois, une version plus explicite serait :

Python Exécuter

```python
df_merge["mois_de_stock"] = np.nan

masque_vendu = (
    df_merge["total_sales"].notna()
    & (df_merge["total_sales"] > 0)
    & df_merge["stock_quantity"].notna()
)

df_merge.loc[masque_vendu, "mois_de_stock"] = (
    12
    * df_merge.loc[masque_vendu, "stock_quantity"]
    / df_merge.loc[masque_vendu, "total_sales"]
)
```

Gemini me dit par contre que cela n'est pas traité par le notebook, ce qui est faux :

- **Gestion des marges non implémentée :**
  - L'analyse de la rentabilité (taux de marge, rotation des stocks, nombre de mois de stock) demandée par le CODIR n'est pas traitée dans le code du notebook.

Je corrige donc mes cellules suivant les indications de ChatGPT. De plus, ChatGPT détecte 3 erreurs :

- “Ne pas remplacer les valeurs infinies par zéro : un produit avec du stock mais aucune vente n'a pas zéro mois de stock. Il doit être identifié comme un produit sans ventes.
- Traiter les valeurs manquantes et les ventes négatives pour éviter des indicateurs trompeurs.
- Améliorer le classement du flop 20 en sélectionnant les produits ayant le plus de mois de stock, tout en excluant les produits dont cet indicateur ne peut pas être calculé.”

Avant :

Etape 5.3 - Analyse des stocks

```
####################################
# Calculer le nombre de mois de stock #
####################################

#Import de numpy
import numpy as np
#Création de la colonne Rotation de stock
df_merge['rotation_stock'] = df_merge['stock_quantity'] / (df_merge['total_sales'] / 12)
#Remplacement des "inf" par 0
df_merge['rotation_stock'] = df_merge['rotation_stock'].replace([np.inf, -np.inf], 0)
#Effectuer le tri dans l'ordre décroissant du nombre de mois de stock dans le dataset df_merge
df_sorted_stock = df_merge.sort_values(by='rotation_stock', ascending=False)
#Graphique en barre du flop 20 des produits qui ont le plus de mois de stock
flop20 = df_sorted_stock.head(20)
import plotly.express as px

fig = px.bar(
    flop20,
    x='post_title',
    y='rotation_stock',
    title="Flop 20 - Produits avec le plus de mois de stock",
    labels={"post_title": "Produit", "rotation_stock": "Mois de stock"}
)

fig.show()
```



Après :

```
####################################
# Calculer le nombre de mois de stock #
####################################

#Import de numpy
import numpy as np

# 1. Calcul du nombre de mois de stock
# Hypothèse : total_sales correspond aux ventes des 12 derniers mois

df_merge["mois_de_stock"] = np.nan

# On calcule l'indicateur uniquement si les données sont valides
masque_valide = (
    df_merge["stock_quantity"].notna()
    & df_merge["total_sales"].notna()
    & (df_merge["stock_quantity"] >= 0)
    & (df_merge["total_sales"] > 0)
)

df_merge.loc[masque_valide, "mois_de_stock"] = (
    df_merge.loc[masque_valide, "stock_quantity"]
    / (df_merge.loc[masque_valide, "total_sales"] / 12)
)

# 2. Identifier les produits en stock sans ventes
df_sans_ventes = df_merge[
    (df_merge["stock_quantity"] > 0)
    & (df_merge["total_sales"] == 0)
].copy()

print("Produits en stock sans ventes :", len(df_sans_ventes))

# 3. Trier les produits par nombre de mois de stock décroissant
df_sorted_stock = (
    df_merge[df_merge["mois_de_stock"].notna()]
    .sort_values(by="mois_de_stock", ascending=False)
)

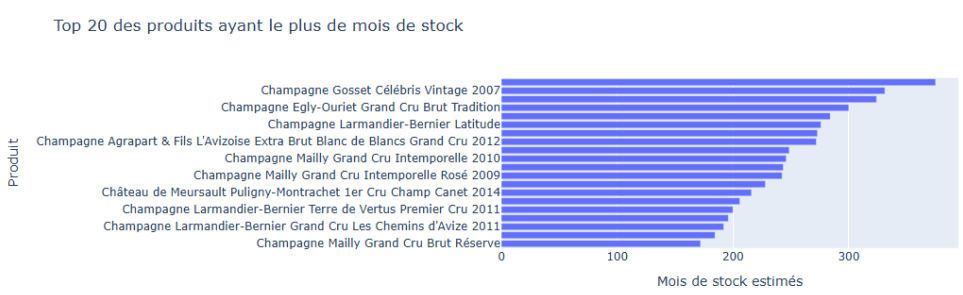
# 4. Sélectionner les 20 produits ayant le plus de mois de stock
flop20 = df_sorted_stock.head(20).copy()
```

```
# 5. Graphique
fig = px.bar(
    flop20.sort_values("mois_de_stock", ascending=True),
    x="mois_de_stock",
    y="post_title",
    orientation="h",
    title="Top 20 des produits ayant le plus de mois de stock",
    labels={
        "mois_de_stock": "Nombre de mois de stock",
        "post_title": "Produit"
    },
    hover_data=["stock_quantity", "total_sales"]
)

fig.update_layout(
    yaxis={"categoryorder": "total ascending"},
    xaxis_title="Mois de stock estimés",
    yaxis_title="Produit"
)

fig.show()
```

```
Produits en stock sans ventes : 3
```



On remarque qu'on ne retrouve pas les mêmes produits dans les mêmes positions.

4. Correction du Pareto

Problématique : les prix ne sont pas classés par ordre décroissant avant de calculer le pourcentage cumulé.

Avant :

```
############################
# Calculer le 20 / 80 en CA #
############################

#Créer une colonne calculant la part du CA de la ligne dans le dataset
df_merge['part_ca'] = df_merge['ca_par_article'] / df_merge['ca_par_article'].sum()
#Créer une colonne réalisant la somme cumulative de la colonne précedemment créée
df_merge['part_ca_cumulee'] = df_merge['part_ca'].cumsum()
#Grâce aux deux colonnes créées précedemment, calculer le nombre d'articles représentant 80% du CA
nb_articles_80 = (df_merge['part_ca_cumulee'] <= 0.8).sum()
print('Articles représentant 80% du CA:', nb_articles_80)
#Afficher la proportion que représente ce groupe d'articles dans le catalogue entier du site web
proportion = nb_articles_80 / len(df_merge) * 100
print('Part du CA :', proportion.round(2), '%')
```

```
Articles représentant 80% du CA: 434
Part du CA : 52.61 %
```

Après :

```
# Tri décroissant du chiffre d'affaires
df_pareto = df_pareto.sort_values(
    by="chiffre_affaires",
    ascending=False
).reset_index(drop=True)

# Calcul du chiffre d'affaires cumulé
df_pareto["ca_cumule"] = df_pareto["chiffre_affaires"].cumsum()

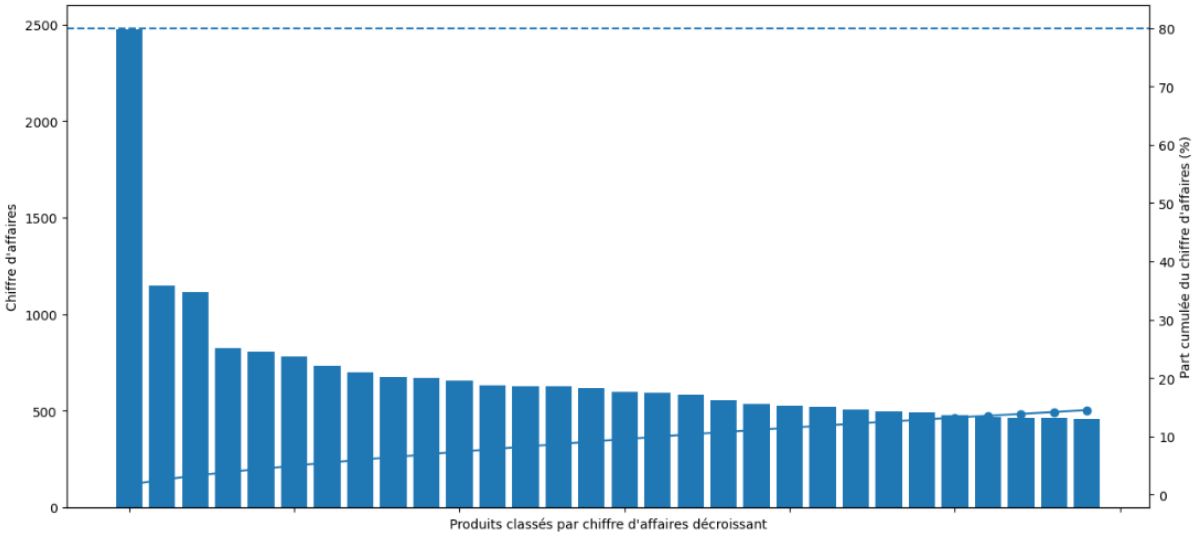
# Calcul de la part cumulée du chiffre d'affaires
ca_total = df_pareto["chiffre_affaires"].sum()

df_pareto["part_cumulee"] = (
    df_pareto["ca_cumule"] / ca_total
) * 100

# Affichage des premières lignes
df_pareto.head(10)
```

	post_title	chiffre_affaires	ca_cumule	part_cumulee
0	Champagne Egly-Ouriet Grand Cru Millésimé 2008	2475.0	2475.0	1.722577
1	Coteaux Champenois Egly-Ouriet Ambonnay Rouge ...	1147.8	3622.8	2.521435
2	Champagne Egly-Ouriet Grand Cru Brut Rosé	1113.0	4735.8	3.296072
3	Agnès Levet Côte Rôtie Améthyste 2017	824.0	5559.8	3.869569
4	Domaine des Comtes Lafon Volnay 1er Cru Santen...	805.0	6364.8	4.429841
5	Champagne Agrapart & Fils Minéral Extra Br...	781.2	7146.0	4.973549
6	Domaine des Comtes Lafon Volnay 1er Cru Santen...	735.0	7881.0	5.485102
7	Camille Giroud Clos de Vougeot 2016	700.0	8581.0	5.972295
8	Champagne Gosset Célébris Vintage 2007	675.0	9256.0	6.442089
9	Champagne Agrapart & Fils L'Avizoise Extra...	672.0	9928.0	6.909795

Ajout d’un diagramme :




```python
# Nombre de produits nécessaires pour atteindre au moins 80 % du CA
produits_80 = df_pareto[
    df_pareto["part_cumulee"] < 80
]

nombre_produits_80 = len(produits_80) + 1

part_produits = (
    nombre_produits_80 / len(df_pareto)
) * 100

print(f"Nombre total de produits : {len(df_pareto)}")
print(
    f"Nombre de produits nécessaires pour atteindre "
    f"80 % du CA : {nombre_produits_80}"
)
print(
    f"Ces produits représentent {part_produits:.2f} % "
    f"du nombre total de produits."
)
```

```
Nombre total de produits : 711
Nombre de produits nécessaires pour atteindre 80 % du CA : 433
Ces produits représentent 60.90 % du nombre total de produits.
```

5. Correction de l'interprétation des corrélations

Interprétation des corrélations

Stock et ventes (+0,439) : corrélation positive modérée

Les produits ayant des quantités en stock plus élevées tendent à présenter des ventes totales plus élevées. Cette relation reste modérée : elle ne concerne pas systématiquement tous les produits et ne démontre pas que le stock élevé provoque une hausse des ventes.

Prix et ventes (−0,517) : corrélation négative modérée

Les produits les plus chers tendent à présenter des ventes totales plus faibles. C'est la relation la plus marquée de la heatmap. Elle peut suggérer une sensibilité des ventes au prix, mais d'autres facteurs, comme la popularité du produit ou les promotions, peuvent également intervenir.

Stock et prix (−0,091) : corrélation quasi nulle

Il n'existe pratiquement pas de relation linéaire entre le prix et la quantité en stock dans les données étudiées. Les produits chers ne semblent donc pas systématiquement avoir des stocks plus faibles ou plus élevés.

6. Présentation du Notebook



Plusieurs étapes me sont proposées afin de rendre le Notebook davantage présentable :

- Redéfinir l'objectif du Notebook et supprimer le texte présentant le fonctionnement de Jupyter (commentaires présents pour la formation).
- Réorganiser les cellules en grandes sections
- Nettoyer les cellules de code
- Séparer le nettoyage des données de l'analyse
- Reprendre proprement la partie Great Expectations
- Ajouter une véritable narration analytique
- Documenter les limites et les biais

Exemple : suppression de l'introduction précédente (formation OpenClassroom) et ajout d'une introduction présentant le notebook.

Introduction

Dans le cadre de ce projet, l'objectif est d'exploiter les données commerciales du site de vente de vins **Bottleneck** afin de mieux comprendre les ventes, les prix pratiqués, les niveaux de stock et la rentabilité des produits.

Les données proviennent de plusieurs sources, notamment un fichier ERP contenant des informations sur les produits et les stocks, un fichier relatif aux ventes du site web et une table de liaison permettant de rapprocher les références entre les différentes sources.

L'exploitation de ces données nécessite un travail préalable de contrôle, de nettoyage et de consolidation afin de garantir la cohérence des informations utilisées dans les analyses.

Outils et environnement technique

Le projet repose sur les outils suivants :

Python : langage utilisé pour le traitement et l'analyse des données.

Jupyter Notebook : environnement interactif permettant de combiner code, résultats et explications.

Pandas : manipulation, nettoyage et consolidation des données tabulaires.

Bibliothèques de visualisation : exploration graphique des distributions et des relations entre variables.

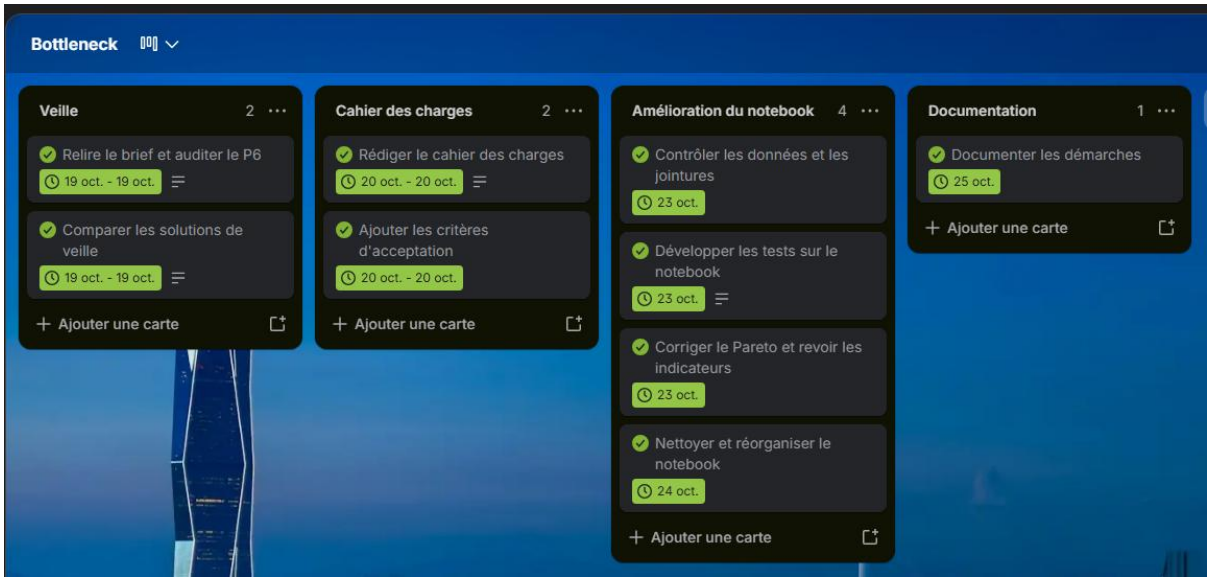
Great Expectations : définition et exécution de contrôles automatisés de qualité des données.

Organisation du projet

Découpage du projet en lots :

Lot	Tâches principales	Livrable	Priorité	Dépendances	Done
Cadrage	Définir les objectifs métier, les indicateurs et les besoins du CODIR	Cahier des charges	Moyenne	Aucune	Les objectifs, les besoins métier, le périmètre et les critères d'acceptation sont définis.
Nettoyage et préparation	Corriger les anomalies justifiées, documenter les transformations et préparer les données	Documentation	Haute	Cadrage	Les anomalies sont identifiées, les corrections sont justifiées et les transformations sont documentées.
Analyse exploratoire	Étudier les ventes, les prix, les marges, les stocks et les corrélations	Notebook	Haute	Nettoyage et préparation	Les analyses sont réalisées, les graphiques sont commentés et les résultats sont interprétés avec prudence.
Amélioration des méthodes	Tester les outils issus de la veille et retenir ceux qui apportent une réelle valeur ajoutée	Comparatif des solutions testées	Moyenne	Cadrage ; nettoyage et préparation	Les solutions sont comparées selon des critères définis, les essais sont documentés et les choix sont justifiés.
Validation	Vérifier les résultats, contrôler les calculs et évaluer les limites des analyses	Notebook validé et contrôles documentés	Haute	Nettoyage et préparation, analyse exploratoire et amélioration des méthodes	Les calculs et les jointures sont vérifiés, les contrôles qualité sont exécutés et les anomalies restantes sont documentées.
Restitution	Construire les visualisations, formuler les recommandations et préparer la présentation	Rapport et support de présentation	Haute	Validation	Les résultats, les recommandations, les limites et les principaux enseignements métier sont présentés clairement.

Utilisation d'un Kanban sur le site Trello :



Registre des risques :

Ces points constituent un risque lors de l'analyse des données :

- contrôle des références ERP sans correspondance Web (pouvant constituer un problème lors de la jointure)
- corrections de données injustifiées (suppressions, corrections via la moyenne des NA, etc.)
- conclusions commerciales trop rapides (notamment lors de l'analyse des corrélations)

Timeline (diagramme de Gantt sur Trello) :

